Safe Reinforcement Learning on the Constraint Manifold: Theory and Applications

在线学习的需求：

- 机器人自适应控制要求策略在部署中持续（适应环境变化或者硬件老化）
- CMDP的离线训练：训练后直接部署无法解决真实世界的动态不确定性
- 需要保证在线学习的每一步都是安全的

同时如果在仿真训练时已经满足鲁棒性约束，迁移到现实时更能保证安全

举例：在一个机械臂避障任务中，机械臂末端需要从起点运动到目标点并在途中避开障碍物，其中有安全约束为机械臂与障碍物之间的距离D(q)> d_safe.扰动是关节控制过程中的噪声（如电机误差或外部力干扰）。

- 当没有扰动（标称情况）
  此时使用ATACOM控制方法：构造约束函数；随后在构造的约束函数切空间生成安全动作，从而严格保证k(q) <= 0
- 当存在扰动
  扰动模型:控制输入受到噪声影响；定理2可以保证机械臂可能短暂进入不安全区域，但是不会完全碰撞到障碍物

通过一个 机械臂避障 的实例，结合ATACOM算法的设计步骤，说明如何从问题建模到控制器实现的全过程。假设机械臂需在避免碰撞（安全约束）的同时完成末端轨迹跟踪（任务目标）。

1. 问题建模
   状态与动力学

- 状态变量：
  $s = [q, \dot{q}] \in \mathbb{R}^{2n}$，其中 q 为关节角度，$\dot{q}$ 为角速度。
- 动力学模型（控制仿射形式）：

$$\dot{s} = \underbrace{\begin{bmatrix} \dot{q} \\ -M(q)^{-1}(C(q,\dot{q})\dot{q} + g(q)) \end{bmatrix}}_{f(s)} + \underbrace{\begin{bmatrix} 0 \\ M(q)^{-1} \end{bmatrix}}_{G(s)} u_s$$

  - $M(q)$：惯性矩阵，$C(q,\dot{q})$：科氏力矩阵，$g(q)$：重力项。
  - 控制输入 $u_s \in \mathbb{R}^n$：关节力矩。

安全约束

- 避障约束（距离函数）：

$$k(s) = d_{\min} - \|p(q) - p_{\text{obs}}\| \leq 0$$

  - $p(q)$：机械臂末端位置，p_{obs}：障碍物位置，$d_{\min}$：最小安全距离。
  - 约束函数 $k(s)$ 需满足 C^1 光滑性（可通过距离场平滑化实现）。

2. ATACOM算法设计步骤
   步骤1：构造约束流形

- 引入松弛变量 $\mu \geq 0$，定义等式约束：

$$c(s, \mu) = k(s) + \mu = 0$$

- 约束流形：

$$\mathcal{M} = \{(s, \mu) \in \mathbb{R}^{2n} \times [0, +\infty) : c(s, \mu) = 0\}$$

  - 投影性质：若 $(s, \mu) \in \mathcal{M}$，则 s 满足原始约束 $k(s) \leq 0$。

步骤2：设计松弛变量动力学

- 动态更新规则（类K函数控制）：

$$\dot{\mu} = \alpha(\mu) u_\mu, \quad \alpha(\mu) = \mu \quad (\text{例：线性函数})$$

  - 控制输入 $u_\mu \in \mathbb{R}$：调节松弛变量的变化速率。
  - 性质：若初始 $\mu(0) > 0$，则 $\mu(t) > 0$ 对所有 $t \geq 0$ 成立（Lemma 1）。

步骤3：增广系统动力学

- 联合系统：

$$\begin{bmatrix} \dot{s} \\ \dot{\mu} \end{bmatrix} = \begin{bmatrix} f(s) \\ 0 \end{bmatrix} + \begin{bmatrix} G(s) & 0 \\ 0 & \alpha(\mu) \end{bmatrix} \begin{bmatrix} u_s \\ u_\mu \end{bmatrix}$$

  - 控制矩阵：

$$J_u(s, \mu) = \nabla_s c(s, \mu) G(s) = \nabla_q k(s) \cdot J_{\text{arm}}(q) \cdot M(q)^{-1}$$

    - $J_{\text{arm}}(q)$：机械臂末端雅可比矩阵。

步骤4：切空间投影

- 切空间基 B_u 计算：
  - 对 J_u 进行SVD分解，取右奇异向量 $B_u \in \mathbb{R}^{(n+1)\times n}$ 满足 $J_u B_u = 0$。
  - 物理意义：B_u 的列向量张成允许的安全控制方向（即不违反约束的力矩组合）。

步骤5：安全控制器

- 控制律（公式12）：

$$\begin{bmatrix} u_s \\ u_\mu \end{bmatrix} = \underbrace{-J_u^\dagger \psi}_{\text{漂移补偿}} + \underbrace{B_u u}_{\text{任务控制}} - \underbrace{\lambda J_u^\dagger c}_{\text{收缩项}}$$

  - 参数说明：
    - $\psi = \nabla_s k(s) \cdot f(s)$：约束对自然动态的敏感度。
    - u：RL策略输出的原始力矩（如跟踪PD控制信号）。
    - $\lambda > 0$：收缩速率。

3. 实例运行流程
4. 初始化：机械臂位于安全位置 s_0，松弛变量 $\mu(0) = \max(-k(s_0), \text{tol})$。
5. 在线控制循环：
   - RL策略输出 u：如目标跟踪的PD控制信号。
   - ATACOM修正：
     - 计算 J_u 和 B_u，投影 u 到切空间。
     - 若机械臂接近障碍物（$k(s) \to 0$），收缩项 $-\lambda J_u^\dagger c$ 主导，产生避障力矩。
   - 执行安全控制 u_s。
6. 结果：机械臂末端绕开障碍物并收敛到目标轨迹（见下图）。

4. 关键设计要点

设计环节	解决方法	实例中的实现
约束建模	距离函数 + 松弛变量	$k(s) = d_{\min} - \|p - p_{\text{obs}}\|$
流形切空间计算	SVD分解控制矩阵 J_u	机械臂雅可比矩阵与惯性矩阵耦合
安全控制律	漂移补偿 + 任务投影 + 收缩项	避障力矩自动生成
动态松弛变量	类K函数控制的 $\dot{\mu}$	保证 $\mu(t) > 0$ 避免数值奇点

5. 数学与物理意义对应

- 切空间投影：将关节力矩限制在“不缩短机械臂与障碍物距离”的方向。
- 收缩项：类似虚拟排斥力，强度随 $k(s)$ 接近0而增大。
- 松弛变量：量化“允许的临时约束违反”，动态调整控制保守性。

几种RL对于约束函数的处理方法

假设约束函数$k(s) \leq 0$, 机械臂与障碍物距离 $D(s) \geq d_{safe}$ 可以表示为 $k(s) = d_safe - D(s) \leq 0$

方法对比与切空间的优越性

以下是针对同一个约束函数，不同安全强化学习方法处理方式的对比分析，结合数学形式、实现逻辑和应用场景的详细说明：

1. 问题设定
   约束函数：

$$k(s) \leq 0$$

（例如：机械臂与障碍物距离 $D(s) \geq d_{\text{safe}}$ 可表示为 $k(s) = d_{\text{safe}} - D(s) \leq 0$）

目标：在强化学习训练和部署中保证 $k(s) \leq 0$ 始终成立。

1. 不同方法对比

(1) 惩罚函数法（Penalty Method）

- 处理方式：
  在奖励函数中加入惩罚项：

$$R_{\text{penalized}} = R_{\text{task}} - \lambda \max(0, k(s))^2$$

  - λ 为惩罚系数，需手动调节。
- 特点：
  - 数学简单：无需修改策略结构。
  - 安全无保证：训练早期可能严重违反约束（如图1左）。
  - 调参敏感：λ 过小导致约束失效，过大抑制探索。
- 适用场景：
  仿真环境预训练，且约束违反无严重后果时。

(2) 安全滤波器（QP-Based Safety Filter）

- 处理方式：
  在线求解二次规划问题，修正动作 u：

$$\begin{aligned} \min_{u} \quad & \|u - u_{\mathrm{RL}}\|^2 \\ \text{s.t.} \quad & \nabla k(s)^T (f(s) + G(s)u) \leq -\alpha k(s) \end{aligned}$$

  - 通过CBF（Control Barrier Function）保证约束。
- 特点：
  - 即时安全：每一步动作均满足约束。
  - 计算开销大：实时求解QP问题（毫秒级延迟）。
  - 可行性风险：约束冲突时无解（如机械臂被“卡死”）。
- 适用场景：
  计算资源充足的实时控制系统（如自动驾驶）。

(3) 备份策略（Backup Policy）

- 处理方式：
  预设安全策略 π_{safe}（如零速度指令），当 $k(s) > \epsilon$ 时切换：

$$u = \begin{cases} u_{\mathrm{RL}} & \text{if } k(s) \leq \epsilon, \\ \pi_{\mathrm{safe}}(s) & \text{otherwise.} \end{cases}$$

- 特点：
  - 简单可靠：硬件易实现。
  - 保守性：任务中断频繁（如图1中）。
  - 泛化性差：需为每个任务单独设计 π_{safe}。
- 适用场景：
  已知明确安全动作的简单系统（如急停按钮）。

(4) 切空间投影（ATACOM，Tangent Space Projection）

- 处理方式：
  i. 构造约束流形 $\mathcal{M} = \{s \mid k(s) = 0\}$ 的切空间 $T_s\mathcal{M}$。
  ii. 将RL动作 u 投影到切空间：

$$u_{\mathrm{safe}} = (I - \nabla k(s)(\nabla k(s)^T \nabla k(s))^{-1} \nabla k(s)^T)u$$

  iii. 动态调整松弛变量 μ 保证渐近收敛（见原文公式12）。
- 特点：

    - 严格安全：数学保证 $k(s) \leq 0$（即使训练中）。
    - 高效：投影计算仅需矩阵乘法（微秒级）。
    - 自适应：无需手动设计安全策略。
- 适用场景：
  高维复杂系统（如机器人、无人机）的在线安全学习。

对比总结表

方法	数学形式	安全性保证	计算效率	是否需要调参	适用场景
惩罚函数法	修改奖励函数	❌ 无	⚡ 最高	✅ 需调λ	无风险仿真
安全滤波器	在线QP优化	✅ 严格	🐢 慢	❌ 无需	高资源实时系统
备份策略	条件策略切换	⚠️ 保守	⚡ 快	✅ 需设计策略	简单硬件系统
切空间投影	几何投影+动态松弛	✅ 严格	⚡ 快	❌ 无需	复杂在线学习

1. 实例说明（机械臂避障）

- 惩罚函数法：
  训练早期机械臂碰撞障碍物（$k(s) > 0$），直到策略学会规避。
- 安全滤波器：
  每个时间步求解QP，保证 $D(s) \geq 0.1$ m，但计算延迟导致控制频率下降。
- 备份策略：
  机械臂接近障碍物时紧急停止，无法完成任务。
- 切空间投影：
  机械臂沿障碍物表面切线运动（$D(s) \equiv 0.1$ m），既安全又完成任务。

1. 核心差异总结
2. 安全性的数学基础：
    - 切空间投影和QP滤波器通过微分几何/优化理论严格保证安全。
    - 其他方法依赖启发式设计。
3. 计算本质：
    - 切空间投影是解析解，QP是数值解，备份策略是规则匹配。
4. 适用性：
    - 切空间方法唯一同时满足实时性、严格安全和自适应学习的要求。

通过这种对比，可以清晰看出为何ATACOM的切空间方法在复杂安全关键任务中具有显著优势。